Grupo 3

Sentimiento en reseñas de electrónica

Proyecto Integrador — Parte I (EC2)
Clasificación de opiniones de usuarios mediante técnicas de aprendizaje automático.

Rodrigo Rivera

Mauricio Rivera

Laura Pérez

Mayte Torrico

Problema, objetivo y criterio de éxito

- **Contexto:**
  - Las reseñas de productos electrónicos contienen opiniones sobre calidad, rendimiento, precio y experiencia de uso.
- **Problema:**
  - Analizar manualmente grandes cantidades de comentarios dificulta identificar tendencias y opiniones de forma eficiente.
- **Objetivo:**
  - Construir un modelo que aproxime la satisfacción expresada en el texto mediante una etiqueta derivada de las estrellas.

Criterios de éxito

Superar de forma clara el baseline Dummy en F1 macro

Comparar modelos clásicos bajo la misma partición y elegir mediante validación

Evaluar con métricas y analizar errores, especialmente en la clase neutra

Favorecer la reproducibilidad mediante semillas fijas, configuraciones versionadas, código modular y resultados guardados.

Dataset, fuente y subconjunto

Variable	Tipo	Uso y significado
review	Texto	Contiene la reseña del producto y constituye la entrada principal del modelo para clasificar el sentimiento.
label	Categórica	Variable objetivo: clasifica la reseña como negativa, neutra o positiva según las estrellas.
rating	Numérica entera	Calificación original de 1 a 5 estrellas, utilizada para generar la etiqueta de sentimiento.
asin	Texto	Identificador del producto reseñado en Amazon.
parent_asin	Texto	Identificador del producto padre o familia de variantes.
helpful_vote	Numérica entera	Cantidad de votos que indican que la reseña fue útil para otros usuarios.
verified_purchase	Booleano	Indica si la compra del producto fue verificada por Amazon.
fecha	Fecha y hora	Fecha de publicación de la reseña, derivada de la marca de tiempo original.

Fuente: Amazon Reviews 2023 — Electronics, McAuley Lab, UCSD.
Fecha de acceso: 16/10/2026.

- Lectura progresiva de aproximadamente 1,5 millones de reseñas (streaming).
- 8 columnas/atributos
- Eliminación de textos con menos de 20 caracteres y duplicados exactos.
- Muestreo balanceado con semilla fija 42.

Subconjunto final: 49.998 reseñas, distribuidas en tres clases:

- Negativo: 16.666
- Neutro: 16.666
- Positivo: 16.666

Construcción de la etiqueta

- 1–2 estrellas → negativo.
- 3 estrellas → neutro.
- 4–5 estrellas → positivo.

Etiqueta débil derivada del rating; rating no se utiliza como predictor.

Calidad de datos y sesgos identificados

- 49.998 reseñas en la muestra final.
- 0 valores faltantes en las variables utilizadas.
- 0 duplicados exactos después de la limpieza.
- **Mediana de longitud:** 41 palabras.
- 499 reseñas se encuentran sobre el percentil 99 de longitud.
- El conjunto original presenta una fuerte concentración en cinco estrellas.
- La muestra balanceada permite comparar modelos, pero no representa la prevalencia natural de Amazon.
- La etiqueta es débil porque el rating puede discrepar con el contenido textual.

Integridad del subconjunto

Indicador	Resultado
Reseñas	49.998
Variables	8
Valores faltantes	0
Duplicados exactos	0
Productos únicos	36.010
Compras verificadas	44.743 (89,5 %)

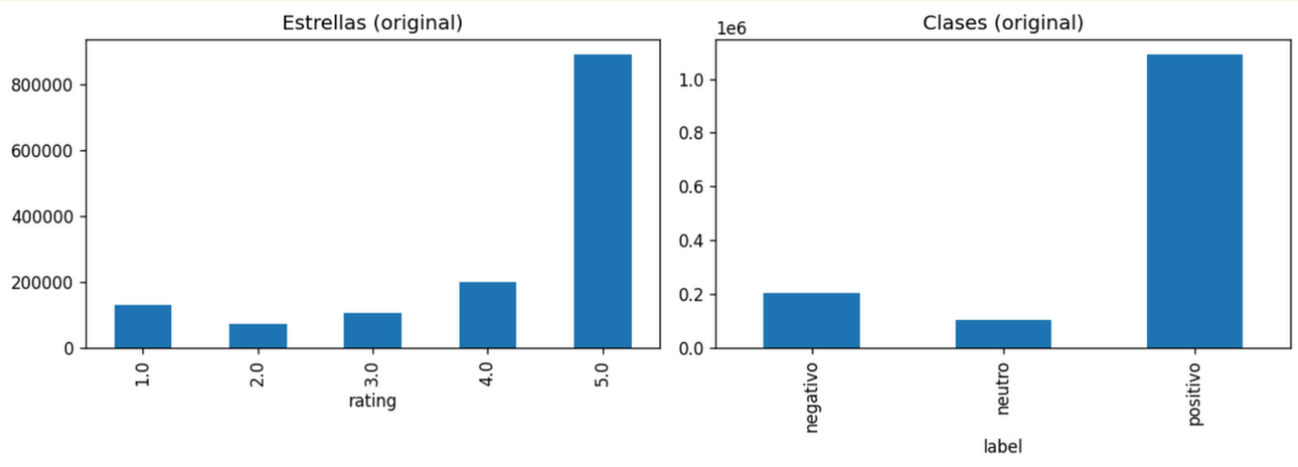
Longitud de las reseñas

Clase	Media	Mediana	Máximo
Negativo	72,1	45	1.624
Neutral	82,6	50	2.828
Positivo	57,6	31	1.729

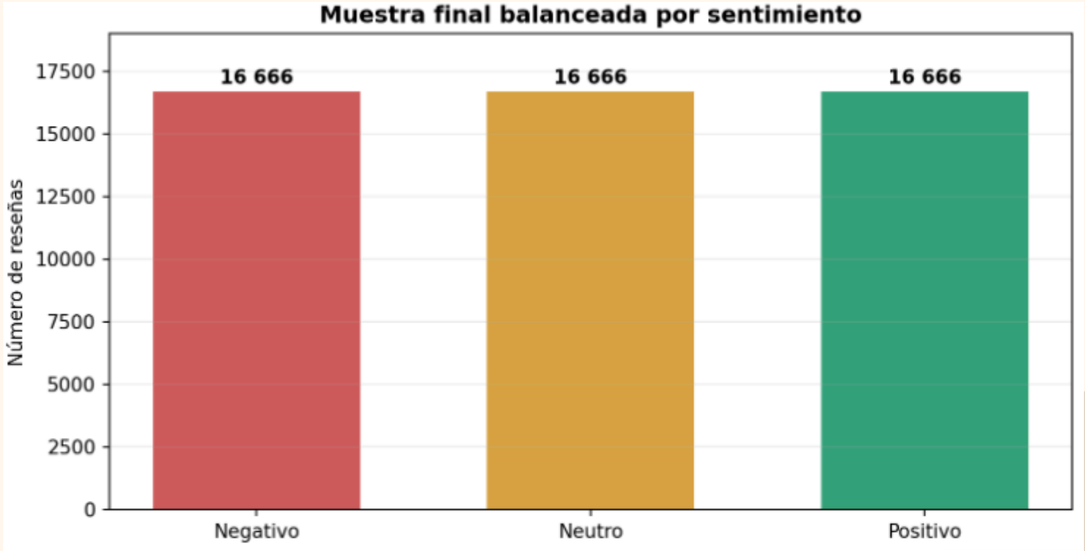
Valores extremos: percentil 99 = 476 palabras. Se identificaron 499 reseñas sobre este umbral y se conservaron para no descartar información sin evidencia.

EDA: Hallazgos clave

1. Desbalance original: justificó el submuestreo balanceado y el uso de F1 macro. El dataset original estaba altamente concentrado en 5 estrella, calificaciones altas



Distribución original por estrellas

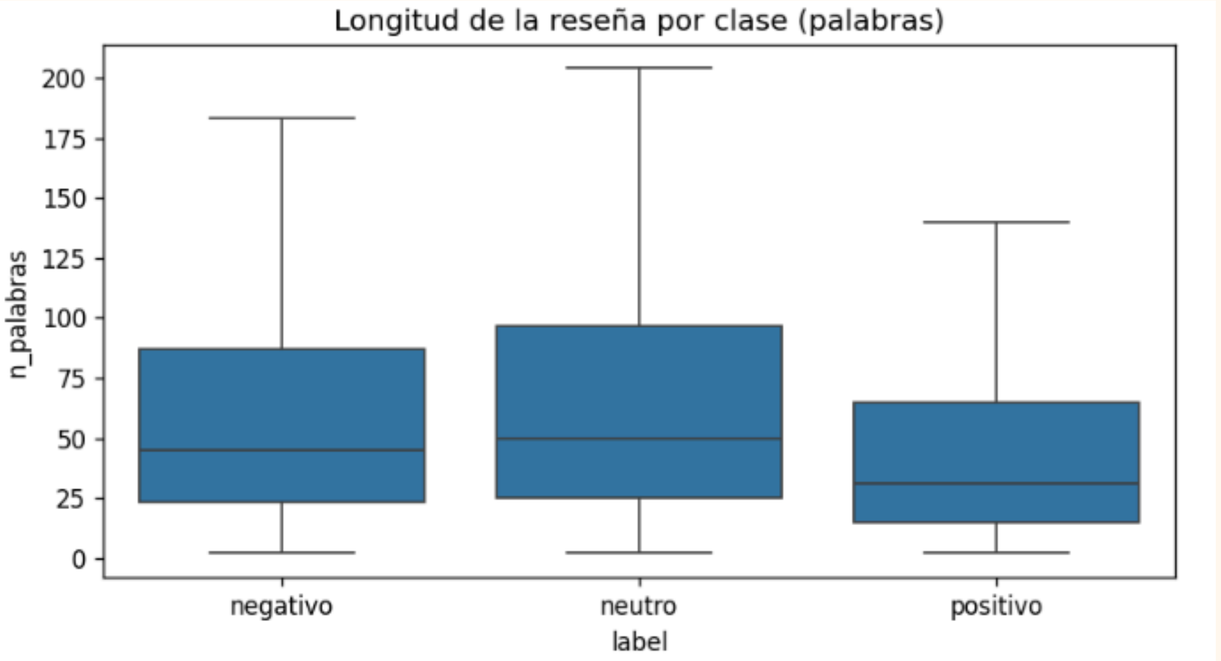


49 998 reseñas: 16 666 por clase

EDA: Hallazgos clave

2. Neutro semánticamente mixto: Se anticipó que sería la clase más difícil y motivó reportar su F1. Las 3 estrellas mezclan elogios parciales con quejas severas

3. Cola larga de longitud: Se conservaron reseñas extensas, ya que pueden dominar conteos o contener varios temas; se conservan para no descartar información, mientras TF-IDF normaliza su influencia.



Distribución de longitud utilizada para diagnosticar reseñas extremadamente largas

EDA: Hallazgos clave

4. Negaciones informativas: Se conservaron `not`, `no`, `never` y bigramas como `not work`.
5. Títulos que revelan estrellas: Expresiones como `Five Stars` se eliminaron porque revelan directamente la etiqueta; mantenerlas elevaba el F1 macro de manera artificial de aproximadamente 0,748 a 0,765.

Clase	Ejemplo de reseña	Interpretación
Negativo	“The product arrived damaged and cracked... the quality seems very cheap.”	El producto llegó dañado y el usuario considera que su calidad es deficiente.
Negativo	“4GB RAM is NOT enough... this computer started freezing and crashing.”	El usuario reporta memoria insuficiente y problemas de rendimiento del equipo.
Neutro	“I first purchased the slik sprint but it was way too light and flimsy... I returned that one and bought the...”	Describe una experiencia de compra y compara productos, destacando problemas con el primero y la decisión de
Neutro	“Writing is pretty good, but... it just isn't convenient enough to replace the old pen and paper.”	Presenta una valoración mixta: reconoce una ventaja, pero señala que el producto no resulta suficientemente práctico.
Positivo	“It exceeded my expectations. I liked all of its features.”	Manifiesta satisfacción y afirma que el producto superó sus expectativas.
Positivo	“Best deal EVER on a camera case... it fits perfectly... Love it!”	Destaca la buena relación calidad-precio, el ajuste adecuado y la satisfacción del usuario.

Preparación de datos

Limpieza

- Conversión a minúsculas y eliminación de URLs y números.
- Normalización de espacios manteniendo signos ! y ?
- Expansión de negaciones (don't → do not) para conservar la carga afectiva.
- Eliminación de títulos automáticos: Se descartaron títulos como "Five Stars" por filtrar directamente la etiqueta.

Partición y prevención de Leakage

- Exclusión estricta de rating y label: no forma parte de las variables de entrada.
- Encapsulamiento en Pipeline: TF-IDF y SVD se ajustan únicamente con datos de entrenamiento.
- Los hiperparámetros y el modelo se eligen mediante validación; test se utiliza una sola vez para el reporte final.

64 %
Entrenamiento
31 998

16 %
Validación
8000

20 %
Test
10 000

Baseline y modelos supervisados

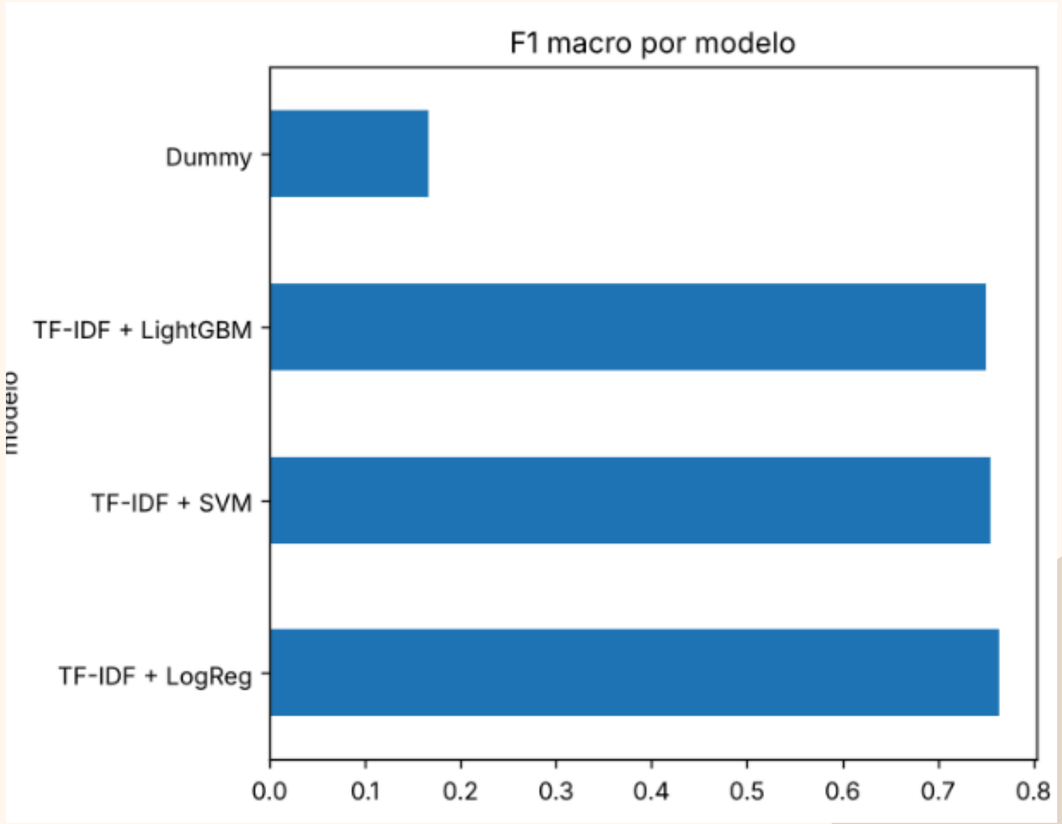
Se utiliza F1 macro porque asigna la misma importancia a negativo, neutral y positivo, independientemente de su frecuencia.

BASELINE
Dummy Classifier
Predice la clase más frecuente y establece el punto de partida.
F1_val = 0,167

Hiperplano
SVM lineal
Clasificador lineal basado en margen máximo.
F1_val = 0,731

Árboles - Gradient Boosting
LightGBM
Alternativa no lineal basada en boosting
F1_val = 0,728

Modelo Lineal
LogReg
Se probaron C={0,5; 1; 2; 4; 8}. Mejor F1_val con C=1
F1_val = 0,741

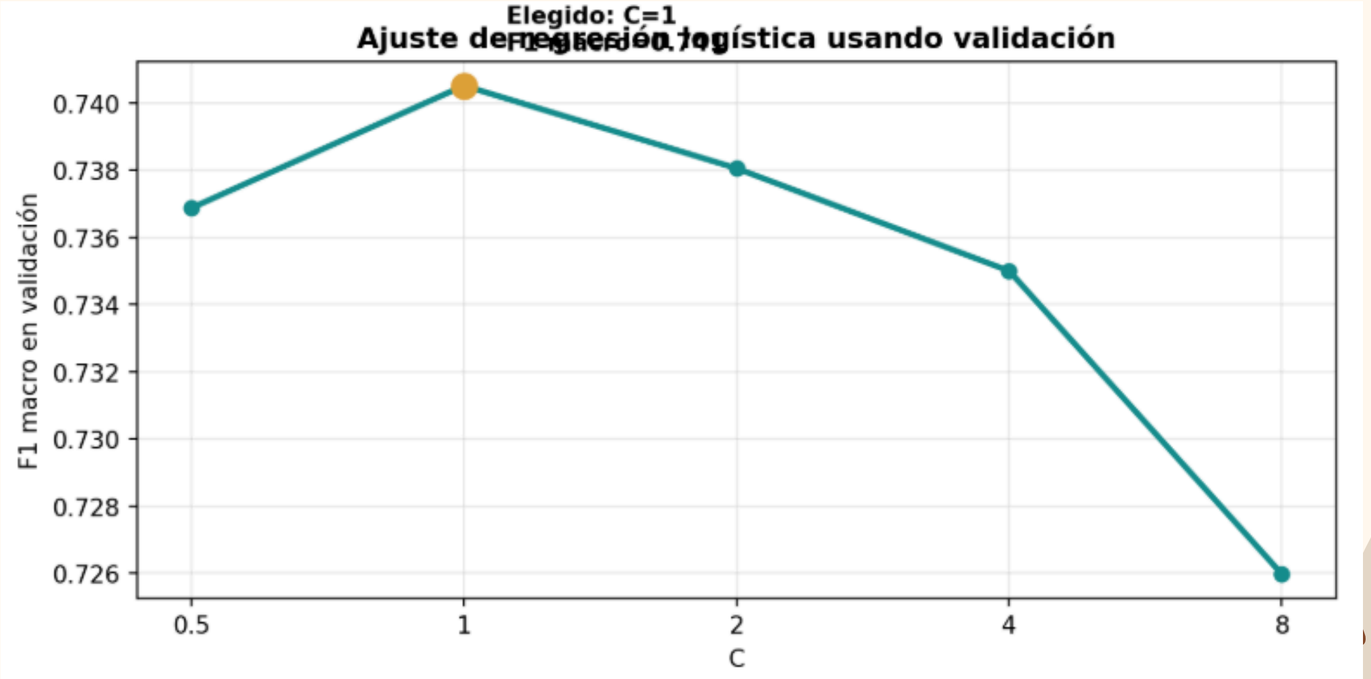


Selección del hiperparámetro C

Para optimizar la Regresión Logística realizamos un ajuste de hiperparámetros

- Probando cinco valores de C: 0,5, 1, 2, 4 y 8. Este parámetro controla la intensidad de la regularización del modelo.
- Comparamos los resultados mediante el F1 macro sobre el conjunto de validación y obtuvimos el mejor valor con C igual a 1, alcanzando 0,7405.

C	F1 validación
0,5	0,7369
1	0,7405
2	0,7381
4	0,735
8	0,726



C=1 se seleccionó exclusivamente con validación. El conjunto de test se reservó para la evaluación final.

Resultados, tabla de métricas

Modelo	F1 val	Accuracy Test	F1 test	F1 neutro	Tiempo
LogReg C=1	0,741	0,748	0,748	0,653	16,9 s
SVM lineal	0,731	0,738	0,737	0,632	7,8 s
LightGBM	0,728	0,731	0,732	0,633	259,4 s
Dummy	0,167	0,333	0,167	0	5,9 s

Selección:
Regresión Logística con C=1 fue seleccionada formalmente por su F1 de validación (0,741). Obtuvo el mayor F1 macro de validación entre los modelos comparados y mantuvo un rendimiento consistente en test.

Clase	Precision	Recall	F1	Soporte
Negativo	0,745	0,753	0,749	3 333
Neutro	0,649	0,658	0,653	3 333
Positivo	0,853	0,833	0,843	3 334

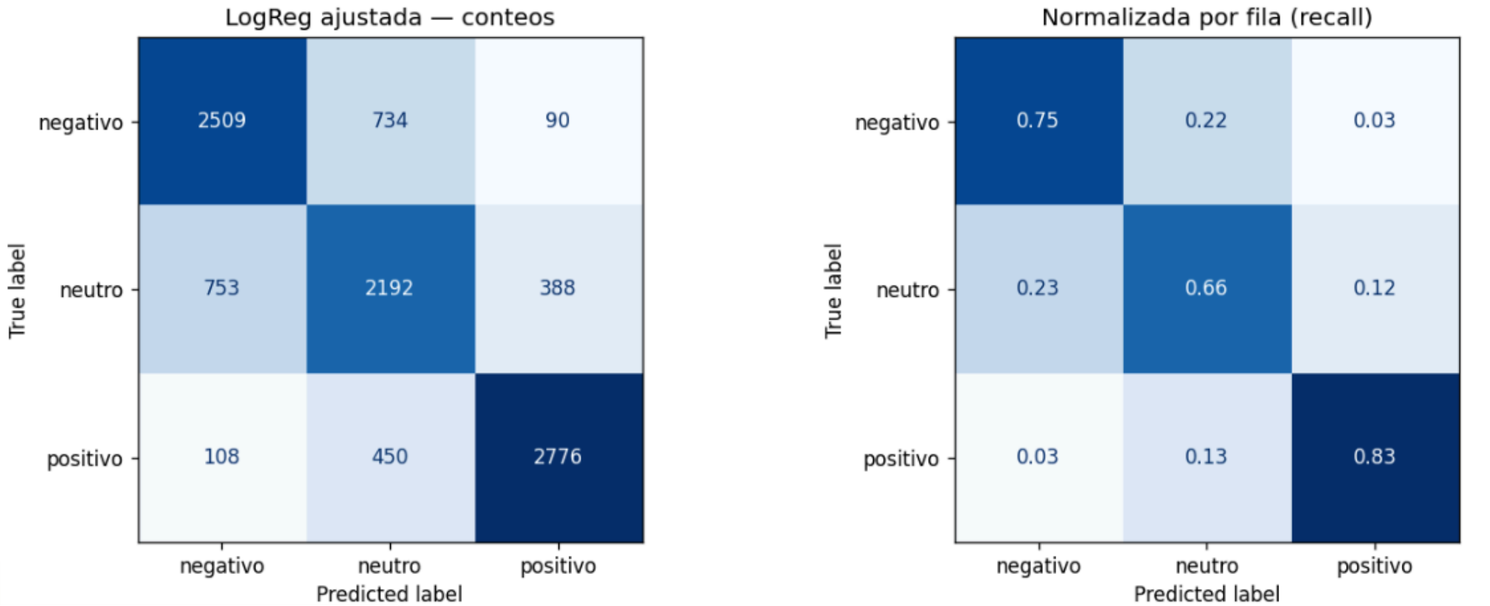
F1 macro es la métrica principal porque pondera por igual las tres clases. Accuracy se reporta como métrica secundaria y F1 neutro permite vigilar la clase más ambigua

Análisis de Errores

El modelo cometió 2523 errores en 10.000 ejemplos de test.

Confusiones de la clase neutral: Falta de polaridad clara en reseñas de 3 estrellas genera solapamiento en el espacio de palabras clave.

Real → predicción	Casos
neutro → negativo	753
negativo → neutro	734
positivo → neutro	450
neutro → positivo	388
positivo → negativo	108
negativo → positivo	90



Errores de alta confianza: Desacuerdo entre texto y rating; son textos muy breves como `works well` o `for the money ok`: el lenguaje expresa una polaridad clara, pero el rating que generó la etiqueta puede ser neutro o negativo. Esto evidencia ruido de etiqueta, falta de contexto y opiniones mixtas

Selección del método no supervisado

Se busca explorar patrones temáticos en las reseñas sin utilizar la etiqueta de sentimiento para formar los grupos

Configuración:

- TF-IDF + TruncatedSVD: Muestra de 8.000 reseñas y 100 componentes.
- UMAP: 10 dimensiones, n_neighbors=30, min_dist=0.
- HDBSCAN: min_cluster_size=100

Se eligió `min_cluster_size=100` como equilibrio entre cobertura, separación y granularidad.

Min cluster	Clusters	Cobertura	Ruido	Silueta
50	58	84,50%	15,50%	0,674
100	30	75,50%	24,50%	0,568
200	13	60,50%	39,50%	0,494
300	8	53,70%	46,30%	0,464

Método	Resultado	Lectura
K-Means	Siluetas < 0,06	Grupos solapados; k obligatorio
GMM	k=12; silueta 0,0085	Probabilístico, pero términos repetidos
DBSCAN	47,9–72,5 % ruido	Radio global sensible
UMAP HDBSCAN	30 clusters; 75,5 % cobertura	Mejor equilibrio y ruido explícito

Interpretación: Para la configuración final, los términos permiten reconocer patrones asociados con mouse y teclado, cables HDMI y USB, Wi-Fi, cámaras, fundas, audífonos, parlantes, batería y carga, productos que dejaron de funcionar, baja calidad y desperdicio de dinero.

Limitaciones: UMAP puede exagerar la separación visual entre grupos, y HDBSCAN depende de sus parámetros. El ruido no representa datos incorrectos: son textos sin pertenencia densa clara.

Interpretación de los patrones encontrados

Se busca explorar patrones temáticos en las reseñas sin utilizar la etiqueta de sentimiento para formar los grupos

Cluster	Interpretación tentativa	Términos representativos	n	Sentimiento predominante
C0	Valoración ambigua	ok, just ok, not great	104	81.7 % neutral
C2	Fallas con el tiempo	stopped working, months, quit	142	70.4 % negativo
C5	Cables y conectividad	cable, HDMI, USB, connectors	127	53.5 % positivo
C7	Uso sencillo y satisfactorio	works great, easy use, love	240	78.8 % positivo
C16	Desperdicio de dinero	waste money, junk, waste time	145	89.0 % negativo
C22	Fundas y protección	case, cover, screen, protector	540	Mixto

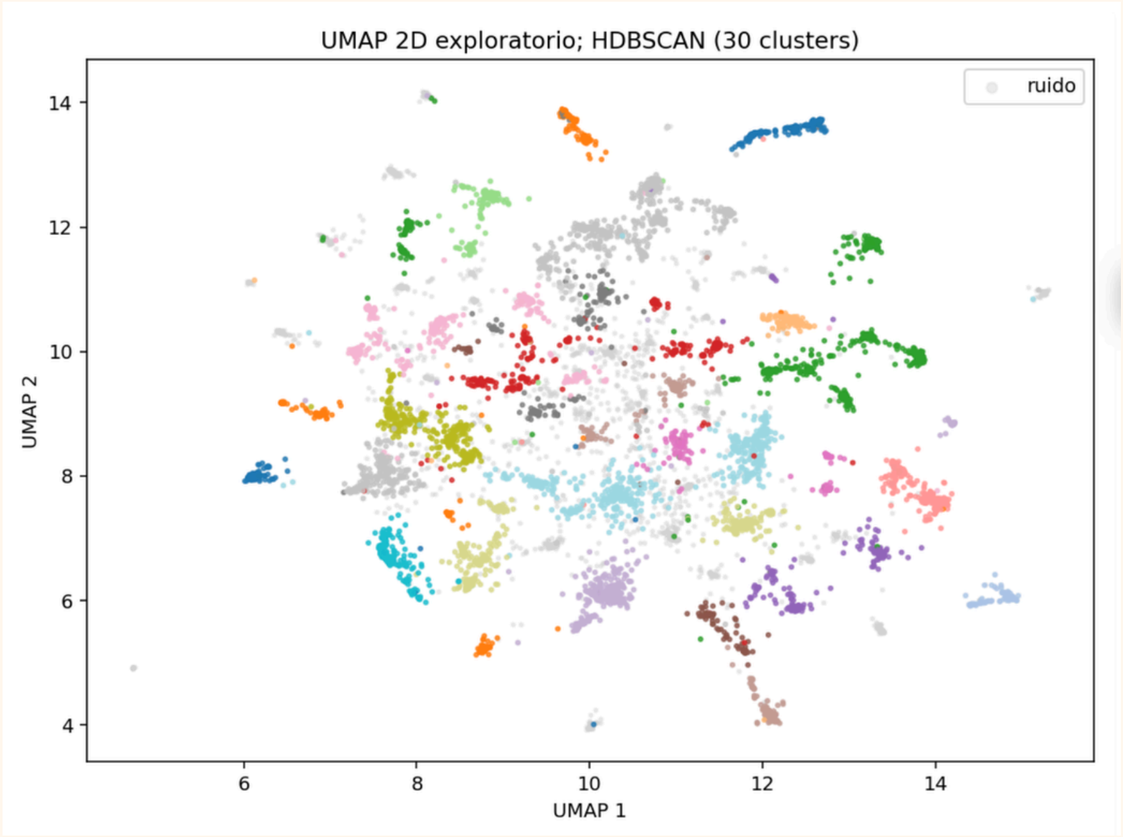
Los nombres son interpretaciones tentativas de patrones léxicos, no categorías reales.

La etiqueta de sentimiento no se utilizó para formar los clusters; se cruzó posteriormente para apoyar su interpretación.

Resultados de UMAP + HDBSCAN

- K-Means y Gaussian Mixture mostraron separación débil.
- UMAP + HDBSCAN produjo grupos más interpretables.
- 30 clusters, 75.5% de cobertura.
- 24.5% se identificó como ruido.
- Los clusters son patrones inducidos, no categorías reales.

Probabilidad media de asignación: 0.886



Proyección UMAP 2D de 8,000 reseñas. El clustering fue realizado en UMAP-10D. Los puntos grises representan ruido.

AutoML

Configuración:

- **Tiempo límite:** 900 segundos (15 minutos) con semilla 42.
- **Partición:** Misma partición 64/16/20 fijada en split.csv.
- **Representación:** TF-IDF reducido a 300 componentes densas con SVD.
- **Familias de modelos habilitadas:** LightGBM, XGBoost, Random Forest, Extra Trees, LogReg L1.
- **FLAML registró 15 trials en 15 minutos:** 10 de LightGBM (F1 de validación hasta 0,696) y 5 de regresión logística L1 (hasta 0,716), que fue la mejor familia

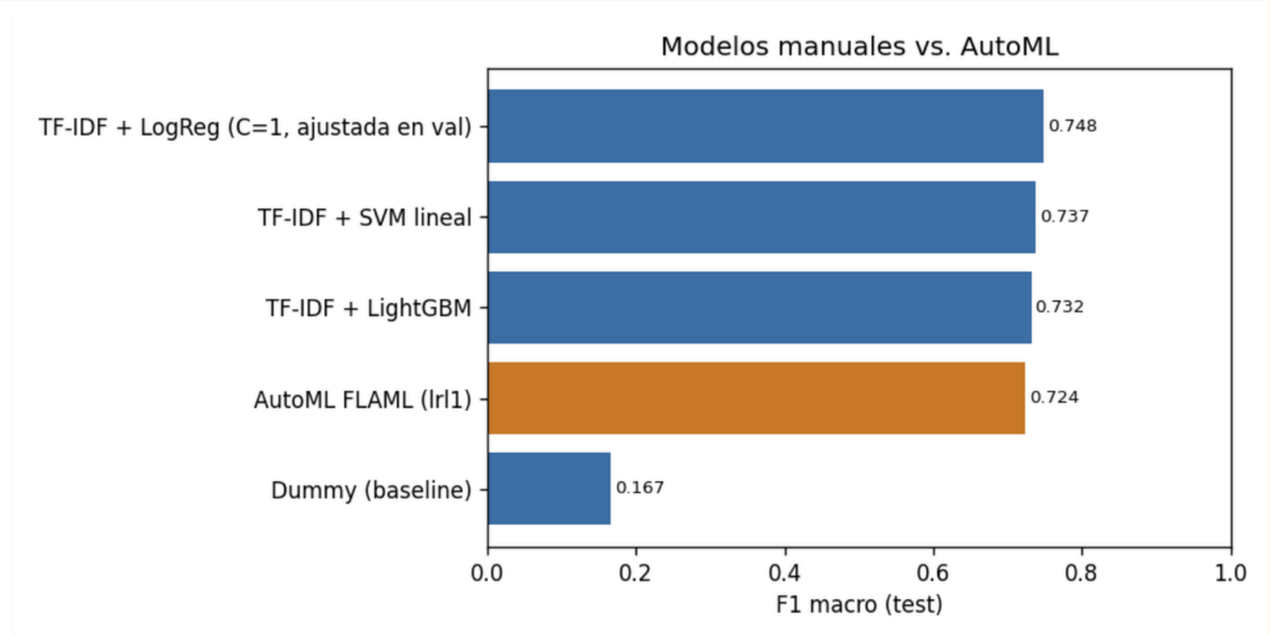
Comparación con el enfoque manual

- El modelo manual superó por +0.024 en F1 Test y se ejecutó 56 veces más rápido. La compresión a 300 componentes SVD en AutoML perdió señal léxica fina.
- En el enfoque manual decidimos la limpieza, los n-gramas y el ajuste de C. En AutoML solo controlamos la representación de entrada, el presupuesto y la lista de estimadores
- Sin que se lo indicáramos, AutoML también terminó eligiendo un modelo lineal por encima de los árboles con boosting

Enfoque	F1 val	F1 test	F1 neutro	Tiempo
LogReg manual C=1	0,741	0,748	0,653	16,9 s
FLAML LogReg L1	0,716	0,724	0,63	945,8 s

Conclusiones del modelado supervisado

- La regresión logística fue el mejor modelo.
- F1 macro de validación: 0.741.
- F1 macro de test: 0.748.
- La clase neutral fue la más difícil.
- Los modelos lineales fueron más eficientes.
- LightGBM no justificó su mayor costo.



Regresión logística
C = 1

- **F1 validación: 0.741**
- **F1 test: 0.748**
- **F1 neutral: 0.653**
- **Tiempo: 16.9 s**

La regresión logística fue seleccionada por su F1 macro de validación; el test se utilizó únicamente para la evaluación final.

Limitaciones del trabajo

- Etiqueta derivada de estrellas.
- Posible discrepancia entre rating y texto.
- Muestra balanceada distinta de la prevalencia real.
- Clustering aplicado a una muestra de 8,000.
- UMAP introduce aleatoriedad y distorsión.
- HDBSCAN depende de hiperparámetros.
- AutoML tuvo presupuesto limitado.
- No se realizó validación humana formal de clusters.



Trabajo futuro para la Parte II

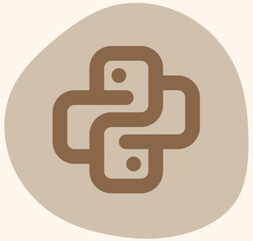
- Incorporar embeddings semánticos.
- Desarrollar recuperación semántica.
- Validar clusters con evaluación humana.
- Analizar estabilidad entre semillas.
- Probar otras categorías de productos.
- Evaluar datos con distribución natural.
- Construir una interfaz de consulta.



Reproducibilidad, herramientas y apoyos utilizados

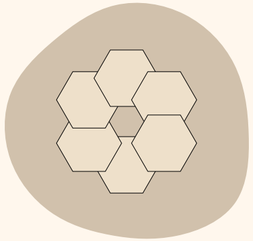
Librerias principales

- pandas y NumPy.
- scikit-learn.
- LightGBM.
- FLAML.
- UMAP.
- HDBSCAN.
- Matplotlib y Seaborn.



Reproducibilidad

- Semillas fijas.
- Configuraciones versionadas.
- Resultados guardados en reports/.
- Modelos guardados en models/.
- Instrucciones de ejecución en el README.



Apoyo externo

- Documentación oficial.
- Asistentes de IA como apoyo para código, revisión y redacción.
- Resultados verificados mediante ejecución y análisis del equipo.



Conclusiones finales

- La regresión logística obtuvo el mejor desempeño supervisado y superó a **SVM**, **LightGBM** y **FLAML** bajo el protocolo definido.
- Su principal ventaja fue el equilibrio entre rendimiento, costo computacional e interpretabilidad.
- La clase neutral obtuvo el menor F1 debido a las opiniones mixtas y al ruido de la etiqueta derivada de estrellas.
- El conjunto de test permaneció aislado hasta la evaluación final.
- UMAP + HDBSCAN permitió identificar patrones temáticos más interpretables, sin asumir que constituyen categorías reales.
- AutoML no superó el enfoque manual dentro del presupuesto establecido.
- El modelo supervisado aproxima la satisfacción; el análisis no supervisado explora los temas presentes en las reseñas.



Gracias
por tu
atención